## Netflix Data Warehouse

Susan Hidalgo, Brenda Rojas, Cristopher Rodriguez, Melani Vargas

shidalgo70985@ufide.ac.cr brojas60567@ufide.ac.cr

crodriguez00279@ufide.ac.cr

mvargas30424@ufide.ac.cr

Universidad Fidélitas, Ingeniería en Sistemas Computacionales, Heredia, Costa Rica

Data Warehouse

(SC-602)

Grupo #1

Resumen— Se quiere realizar una investigación a profundidad de la empresa Netflix para poder llegar a crear un Data Warehouse que logre satisfacer a la empresa y sus necesidades, tomando en cuenta datos proporcionados por el sitio Kaggle, donde se obtuvo información de los títulos que actualmente presenta la aplicaciones e información como sus géneros, fechas de lanzamiento, países entre otros.

Palabras Claves- Data Warehouse, Netflix, Kaggle, Streaming

Abstract—We want to carry out an in-depth investigation of the Netflix company in order to create a Data Warehouse that manages to satisfy the company and its needs, taking into account data provided by the Kaggle site, where information was obtained on the titles that the applications currently present and information such as their genres, release dates, countries among others.

Keywords- Data Warehouse, Netflix, Kaggle, Streaming

#### I. CAPÍTULO DE INTRODUCCIÓN

## > INTRODUCCIÓN

Para nuestro proyecto de investigación del curso Data Warehouse hemos decidido basarnos en la famosa aplicación Netflix, la cual se basa en presentarle al comprador de la mensualidad de la aplicación una amplia gama de películas, series y shows televisivos donde se pueden descargar para ver sin internet, ver las películas o series en múltiples idiomas, entre otras muchísimas ventajas que nos ofrece el sitio.

En sus inicios Netflix era un centro de alquiler y venta de DVDs, pero sus fundadores Reed Hastings y Marc Randolph vieron un gran potencial en la venta de peliculas en linea, su nombre se debe a la unión de las palabras "internet" y "flicks" lo cual significa peliculas

Con el pasar de los años Netflix ha ganado un puesto en el mercado muy importante siendo prácticamente la aplicación de

películas y series número 1 a nivel mundial, esto permitiéndoles no solo ser una plataforma de streaming sino que también les dio la oportunidad de empezar a grabar su propio contenido incluyendo series y películas, esto se debe también gracias a la pandemia ya que en el 2020 su uso se disparó de una manera estratosférica, actualmente cuenta con una base de datos muy amplia con diferentes países, fechas de lanzamientos, géneros de películas y series, lo que nos permite poder desarrollar diferentes gráficas, esquemas e investigaciones para poder profundizar más en una funcionalidad que logre satisfacer a la empresa.

#### ➤ OBJETIVOS

Objetivo general:

Desarrollar un Data Warehouse funcional que permita la optimización de un análisis estratégico de contenido en Netflix mediante la integración eficiente de datos proveniente de diversas fuentes, contando el sistema con tiempos de respuesta inferiores a un segundo para consultas claves y ofrecer soporte a la toma de decisiones empresariales relacionadas con la planificación de contenido, análisis de popularidad y tendencias del mercado.

Objetivos específicos:

- Implementar un proceso de extracción, transformación y carga (ETL) que procese datos clave, como géneros de contenido, países, métricas de popularidad y reseñas de usuario para garantizar la calidad, consistencia y disponibilidad de información en el Data Warehouse..
- Diseñar un modelo multidimensional en el Data Warehouse basado en un modelo estrella para analizar el comportamiento del consumo de contenido según criterios como género, país, fecha de lanzamiento y popularidad, optimizando así el diseño para consultas rápidas y análisis detallados.
- Integrar herramientas de virtualización como Power BI, para generar reportes interactivos que muestran distintos

patrones de consumo, tendencias de popularidad por género y país, y métricas de desempeño financiero, ayudando a que las visualizaciones tomen decisiones estratégicas basadas en datos.

#### > ANTECEDENTES

Al pasar los años la tecnología ha sido parte de cada innovación que se ha presentado en el mundo, esto también fue visto en el alquiler o renta de películas, ya que la fundación de Netflix se remonta a que uno de sus fundadores se atrasó en devolver una película a la tienda de videos y se le cobró una multa, debido a esto él decidió crear un sistema nuevo donde se pagará por mes y no existieran esos cobros o multas por atrasos de devolución, al pasar los años la venta de peliculas en linea a sido todo un éxito permitiendo que la empresa de Netflix creciera y se convirtiera en lo que hoy en día conocemos, tantos años de trayectoria involucra muchísimos datos e información la cual podemos usar para dar el mejor funcionamiento y una experiencia de la más alta calidad a todos los usuarios.

#### ➤ JUSTIFICACIÓN

El dataset de Netflix Movies and TV shows que se encuentra disponible en la página Kaggle, proporciona valiosa información acerca de los títulos que actualmente son más vistos en la plataforma, incluyendo detalles como género, país, fechas de lanzamiento, entre otros. Dado al gran volúmen e importancia de estos datos para la toma de decisiones estratégicas en la industria del entretenimiento, se plantea el desarrollo de un Data Warehouse funcional para el análisis y optimización del catálogo de contenido. A su vez, la solución de este proyecto facilitará la integración de diversas fuentes de datos y ayudará con la identificación de tendencias enfocadas en el consumo, popularidad de géneros y análisis de mercado, además la creación de un Data Warehouse optimizará la organización y acceso de datos, mejorando la eficiencia en la toma de decisiones, como la planificación de contenido basado en predicciones de futuras demandas.

## REQUERIMIENTOS FUNCIONALES

- Fuentes de datos: Se utilizarán cinco datasets relacionados con Netflix, disponibles en la plataforma Kaggle. Estos incluyen datos sobre películas y series, reseñas de usuarios, comportamiento bursátil, y la base de usuarios de Netflix. Los datos estarán en formato CSV y serán transformados mediante Pentaho antes de ser almacenados en el Data Warehouse.
- Componentes ETL: El proceso ETL será gestionado por Pentaho, el cual se encargará de extraer los datos desde los archivos CSV, transformarlos y cargarlos en el SQL Server.

#### CARACTERÍSTICAS DE LA SOLUCIÓN

- Pentaho: Una herramienta que se utilizará para llevar a cabo los procesos ETL, es decir, extracción, transformación y carga. Se encargará de integrar los datasets encontrados,, limpiando y transformando los datos según sea necesario antes de almacenarlos en el Data Warehouse.
- SQL Server: Será el sistema de gestión de bases de datos

- donde se implementará el Data Warehouse. Aquí se crearán las tablas de hechos y dimensiones, organizadas bajo un modelo multidimensional como el esquema estrella, lo que permitirá almacenar y organizar la información de forma eficiente.
- Power BI: Se utilizará para generar reportes y visualizaciones a partir de los datos almacenados en el Data Warehouse, de modo que se pueda analizar el rendimiento de los contenidos de Netflix, identificar tendencias y realizar seguimientos de datos financieros.

# II. DIAGRAMAS DE ENTIDAD-RELACIÓN DEL MODELADO DIMENSIONAL

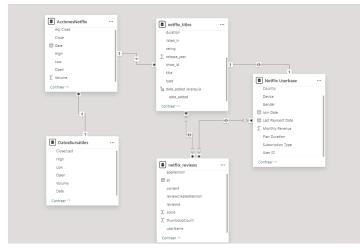


Fig 1 Modelado de Base de Datos de PowerBI

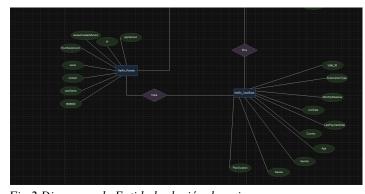


Fig 2 Diagrama de Entidad relación draw.io

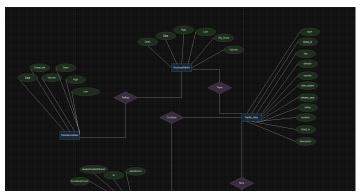


Fig 3 Diagrama de Entidad relación draw.io <a href="https://drive.google.com/file/d/1x2qV4JiYZA8njhZ5">https://drive.google.com/file/d/1x2qV4JiYZA8njhZ5</a> y6 t5Vsxdqmzinhg/view?usp=sharing

### III. DEFINICIÓN DE LAS FUENTES DE DATOS

Los datos utilizados en este proyecto provienen de la plataforma "Kaggle", que ofrece miles de datasets gratuitos para la práctica de análisis de datos. En nuestro caso, decidimos trabajar con datos relacionados con Netflix, una de las plataformas de streaming de películas y series más reconocidas a nivel mundial, con millones de usuarios. Esto nos permitió acceder a una amplia cantidad de información disponible para el análisis.

Los archivos de datos que utilizamos en el proyecto son:

- 1. NETFLIX Stock Data
- 2. Netflix Reviews [DAILY UPDATED]
- 3. Netflix Movies and TV Shows
- 4. Datos Bursátiles de Netflix
- 5. Netflix User Base

Estos archivos contienen una variedad de información, como reseñas de usuarios, rankings de películas y series, los países donde Netflix tiene mayor audiencia, y datos sobre el comportamiento bursátil de la compañía. Todos estos datasets están en formato CSV (texto plano) y fueron abiertos en Excel para obtener una vista más clara y ordenada de su contenido.

El siguiente paso fue integrar los datos en Power BI, donde construimos un modelo de base de datos relacional. A partir de este modelo, generamos un diagrama entidad-relación (ERD) que representaba las conexiones entre las diferentes tablas y los datos.

En total, utilizamos cinco datasets con información diversa. Los datos se organizaron en tablas separadas, estableciendo las relaciones correspondientes a través de claves primarias (PK) y claves foráneas (FK), lo que nos permitió conectar adecuadamente los diferentes conjuntos de datos y realizar un análisis más profundo y visual de la información.

#### IV. FUENTES DE DATOS

Netflix es una de las empresas de streaming más importantes a nivel mundial, es conocida por su amplio repertorio de entretenimiento visual, la compañía se apoya en una cantidad casi inimaginable de datos en sus bases de datos, las cuales son usadas para estrategias comerciales y para mejorar las experiencias de los usuarios, al igual que para tener un control de su plataforma y quienes tengan acceso a ella.

Para nuestro proyecto se estarán analizando diversas fuentes de datos en archivos CSV, las cuales reflejan diferentes áreas importantes de la compañía, a continuación se describirán 5 archivos CSV con datos de la empresa y sus explicaciones de la importancia de cada uno.

#### AccionesNetflix

Este archivo contiene los datos históricos de los precios de las acciones de la compañía de Netflix, cuenta con columnas como Date la cual nos indica la fecha en que los valores fueron registrados, Open indica el precio con el que se abrió la acción en la fecha indicada, High indica el valor más alto al que llegó la acción en la fecha indicada. Low indica el valor más bajo al que llegó la acción en la fecha indicada, Close nos indica en qué momento se cerró las acciones de la fecha indicada, Adj Close indica el precio del cierre ajustado y por último tenemos Volume que es el número de acciones negociadas durante la fecha indicada.

Las columnas tienen valores de tipo numérico decimal o entero y de fecha, los datos comienzan el 23 de mayo del 2002 y luego van incrementando día con día.

El uso que representan estos datos en nuestro proyecto es poder analizar cómo va cambiando el valor en la bolsa de acciones de la empresa de Netflix.

#### Datos Bursátiles

Esta tabla básicamente contiene los datos de las acciones en el mercado financiero del año 2020, las columnas representan los precios y volúmenes de las acciones por dia, cuenta con una columna Date la cual tiene el formato de mes/ día/ año, eso se usa para poder analizar los patrones en los datos, luego contiene un Close/Last el cual se encarga de mostrar el precio del cierre de la acción en ese día específico, luego está el Volume que indica el número de acciones totales en el dia indicado, el Open indica el monto con el que inició la acción en ese dia, High nos indica el monto más alto de la acción en ese dia especifico y por ultimo esta el Low que indica el monto más bajo de la acción en ese día específico.

Este CSV lo incorporamos para poder tener los datos de la parte financiera tanto antiguos los cuales son los del CSV anteriores como los datos un poco más actualizados y así poder comparar los cambios a través del tiempo.

#### Userbase

Este CSV contiene la información de los usuarios, contiene datos como, su User ID para poder llevar un control ordenado, la Subscription Type ya sea el plan básico, el estándar o el premium, la diferencia de un plan a otro es que en el básico cuenta con características limitadas, en el estándar se puede tener acceso a múltiples pantallas y calidad HD y en el premium se tiene acceso ilimitado a las pantallas y calidad UHD. También se tiene los datos de el Monthly Revenue el cual es el ingreso mensual generado por cada usuario, es decir lo que gasta cada uno según el tipo de suscripción que tengan, también tiene la fecha en la que se unió el usuario al servicio, la fecha del ultimo dia que el usuario realizó el pago, el país, la edad, el género el dispositivo que utiliza el usuarios es decir si un celular, computadora o televisor y por último también se tiene la duración del plan, si paga por mes o por año.

Este CSV nos permite analizar los patrones por género, edad, ubicación, o hasta por el tipo de plan de los usuarios, lo cual nos permite la posibilidad de analizar tendencias entre los usuarios de Netflix.

#### Reviews

Este CSV contiene la información sobre las valoraciones y comentarios de los usuarios sobre los títulos que Netflix ofrece, contiene datos como Review Id para poder identificarlo, también tiene un User Id, un Ttle ID, un Rating el cual contiene la puntuación asignada, un Review Date, un Review Text con los

Este CSV es de suma importancia para poder ver las preferencias de los usuarios y sus opiniones tanto de la plataforma como de los títulos que la misma presenta, ya sea sus preferencias por contenido, géneros, o la popularidad.

#### Titles

Este CSV contiene la información de cada uno de los títulos que tiene Netflix en su cartelera o repertorio, algunos de los datos que se pueden recolectar son como el Title ID para poder identificar cada serie o película que se presente, el Title Name, el Release Year para tener los datos de publicación por año de los títulos, el género, la duración ya sea película, serie o otros, también el lenguaje en el que está disponible, algo que podría incluirse es el director o el cast el cual es la lista de actores de los títulos, ademas de la descripción.

Estos datos son importantes porque se pueden agrupar los títulos por año, género, duración, director, actores, entre otros. Esto permite tener un orden de búsqueda y de repertorio lo más acomodado y actualizado posible, esto con el fin de tener la información detallada.

#### V. MODELADO DIMENSIONAL

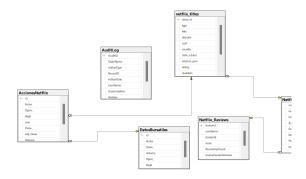


Fig 4 Modelado Dimensional SQL SERVER

#### VI. AVANCE DE LOS PROCESO ETL

Proceso para pasar los datos del archivo CSV de los datos bursátiles de Netflix a una tabla en la base de datos en SQL Server.



Fig. 5 Flujo ETL Datos Bursátiles

Proceso para pasar los datos del archivo CSV de las reviews de Netflix a una tabla en la base de datos en SQL Server.



Fig.6 Flujo ETL Reviews

Proceso para pasar los datos del archivo CSV de las películas de Netflix a una tabla en la base de datos en SQL Server.



Fig.7 Flujo ETL de los títulos de películas

Proceso para pasar los datos del archivo CSV de la userbase de Netflix a una tabla en la base de datos en SQL Server.



Fig.8 Flujo ETL Userbase

Proceso para pasar los datos del archivo CSV de las acciones de Netflix a una tabla en la base de datos en SQL Server.



## VII. AVANCE DE LOS METADATOS

#### AUDITORÍA A NIVEL DE BASE DE DATOS

```
CREATE TABLE AuditLog (
AuditID INT IDENTITY(1,1) PRIMARY KEY,
TableName VARCHAR(100) NOT NULL,
ActionType VARCHAR(50) NOT NULL,
RecordID INT NOT NULL,
ActionDate DATETIME DEFAULT GETDATE(),
UserName VARCHAR(100) NOT NULL,
SourceSystem VARCHAR(100) NOT NULL,
Version INT NOT NULL,
OldValues TEXT NULL,
NewValues TEXT NULL
);
```

Fig 10 Auditoría de tablas

Trigger INSERT de la tabla Netflix Userbase

```
CREATE TRIGGER trg_Userbase_Insert
ON Netflix_Userbase
AFTER INSERT
AS
BEGIN
SET NOCOUNT ON;
```

INSERT INTO AuditLog (TableName, ActionType, RecordID, ActionDate, UserName, SourceSystem, Version, OldValues, NewValues) **SELECT** 'Netflix Userbase' AS TableName, 'INSERT' AS ActionType, i. UserID AS RecordID, GETDATE() AS ActionDate, SYSTEM USER AS UserName, 'ETL Process' AS SourceSystem, 1 AS Version, NULL AS OldValues, CONCAT( 'Subscription Type: ', i.SubscriptionType, ', ', 'Monthly\_Revenue: ', i.MonthlyRevenue, ', ', 'Join Date: ', CONVERT(VARCHAR, i.JoinDate, 120), ', ', 'Last Payment Date: ', CONVERT(VARCHAR,

i.LastPaymentDate, 120), ', ',

```
'Gender: ', d.Gender, ', ',
       'Country: ', i.Country, ', ',
       'Age: ', i.Age, ', ',
                                                                          'Device: ', d.Device, ', ',
       'Gender: ', i.Gender, ', ',
                                                                          'Plan Duration: ', d.PlanDuration
       'Device: ', i.Device, ', ',
                                                                        ) AS OldValues,
       'Plan Duration: ', i.PlanDuration
                                                                       CONCAT(
    ) AS NewValues
                                                                          'Subscription Type: ', i.SubscriptionType, ',
  FROM INSERTED i;
END:
                                                                          'Monthly Revenue: ', i.MonthlyRevenue, ',
GO
                                                                          'Join Date: ', CONVERT(VARCHAR,
                                                                  i.JoinDate, 120), ', ',
                                                                          'Last Payment Date: ',
   7428 ⊟INSERT INTO Netflix Userbase (UserID. SubscriptionType. MonthlyRevenue. JoinDate. LastPaymentDate. Country. Age. Ge
   429 VALUES
430 (34, 'Premium', 15.99, '2024-01-01', '2024-11-01', 'USA', 30, 'Female', 'Mobile', 12);
                                                                  CONVERT(VARCHAR, i.LastPaymentDate, 120),
    EJSELECT *
FROM AuditLog
WHERE TableName = 'Netflix_Userbase
AND ActionType = 'INSERT';
                                                                          'Country: ', i.Country, ', ',
                                                                          'Age: ', i.Age, ', ',
                                                                          'Gender: ', i.Gender, ', ',
                                                                          'Device: ', i.Device, ',
                                                                          'Plan Duration: ', i.PlanDuration
    Fig 11 Resultado Trigger insert en tabla Netflix
                                                                       ) AS New Values
                       Userbase
                                                                     FROM INSERTED i
                                                                     INNER JOIN DELETED d ON i.UserID =
     Trigger UPDATE de la tabla Netflix Userbase
                                                                  d.UserID;
GO
                                                                  END;
CREATE TRIGGER trg Userbase Update
                                                                  GO
ON Netflix Userbase
AFTER UPDATE
AS
                                                              UPDATE Netflix_Userbase
                                                              SubscriptionType = 'Basic',
MonthlyRevenue = 9.99
WHERE UserID = 34;
BEGIN
   SET NOCOUNT ON;
                                                              ESELECT *
FROM Auditlog
WHERE TableName = 'Netflix_Userbase'
AND ActionType = 'UPDATE'
AND RecordID = 34;
   INSERT INTO AuditLog (TableName,
ActionType, RecordID, ActionDate, UserName,
SourceSystem, Version, OldValues, NewValues)
   SELECT
     'Netflix Userbase' AS TableName,
                                                                      Fig 12 Resultado Trigger update en tabla Netflix
     'UPDATE' AS ActionType,
                                                                                          Userbase
     i.UserID AS RecordID,
     GETDATE() AS ActionDate,
     SYSTEM USER AS UserName,
                                                                           Trigger DELETE de la tabla Netflix Userbase
     'ETL Process' AS SourceSystem,
     ISNULL((SELECT MAX(Version) FROM
                                                                  GO
AuditLog WHERE TableName =
                                                                  CREATE TRIGGER trg Userbase Delete
'Netflix Userbase' AND RecordID = i.UserID), 0)
                                                                  ON Netflix Userbase
+ 1 AS Version,
                                                                  AFTER DELETE
     CONCAT(
                                                                  AS
        'Subscription Type: ', d.SubscriptionType,
                                                                  BEGIN
        'Monthly Revenue: ', d.MonthlyRevenue, ',
                                                                   SET NOCOUNT ON;
        'Join Date: ', CONVERT(VARCHAR,
                                                                     INSERT INTO AuditLog (TableName,
d.JoinDate, 120), ', ',
                                                                  ActionType, RecordID, ActionDate, UserName,
        'Last Payment Date: ',
                                                                  SourceSystem, Version, OldValues, NewValues)
CONVERT(VARCHAR, d.LastPaymentDate,
                                                                     SELECT
120), ', ',
                                                                        'Netflix Userbase' AS TableName,
        'Country: ', d.Country, ', ',
                                                                        'DELETE' AS ActionType,
```

d. UserID AS RecordID,

'Age: ', d.Age, ', ',

```
GETDATE() AS ActionDate,
    SYSTEM USER AS UserName,
    'ETL Process' AS SourceSystem,
    ISNULL((SELECT MAX(Version) FROM
AuditLog WHERE TableName =
'Netflix Userbase' AND RecordID = d.UserID), 0)
+ 1 AS Version,
    CONCAT(
       'Subscription_Type: ', d.SubscriptionType,
       'Monthly Revenue: ', d.MonthlyRevenue, ',
       'Join Date: ', CONVERT(VARCHAR,
d.JoinDate, 120), ', ',
       'Last Payment Date: ',
CONVERT(VARCHAR, d.LastPaymentDate,
120), ', ',
       'Country: ', d.Country, ', ',
       'Age: ', d.Age, ', ',
       'Gender: ', d.Gender, ', ',
      'Device: ', d.Device, ', ',
       'Plan Duration: ', d.PlanDuration
    ) AS OldValues,
    NULL AS NewValues
  FROM DELETED d;
END;
GO
```

Fig 13 Resultado Trigger Delete en tabla Netflix Userbase

#### REPORTES EN POWER BI

Recuento de AuditID, Recuento de RecordID y Suma de Version por Año

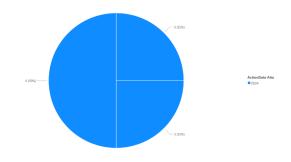


Fig 14 Auditoria Base de Datos

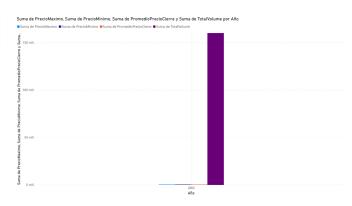


Fig 15 Resumen Acciones Netflix

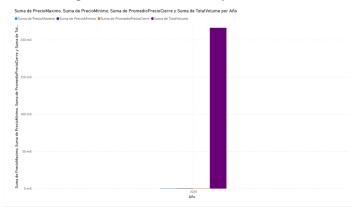


Fig 16 Resumen Datos Bursátiles

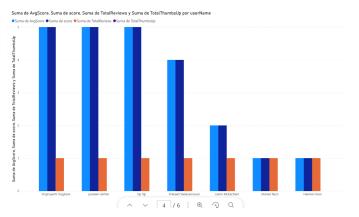


Fig 17 Resumen Netflix Reviews

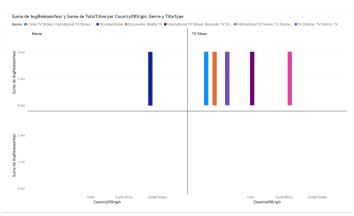


Fig 18 Resumen Netflix titles

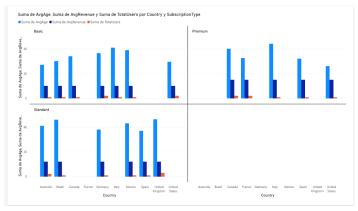


Fig 19 Resumen Netflix Userbase

Reportes Netflix.pdf

## VIII. REFERENCIAS BIBLIOGRÁFICAS

- [1] A. González, "Ésta es la historia del origen de Netflix, la empresa que desplazó a Blockbuster", *Grupo Milenio*, 29-ago-2023. [En línea]. Disponible en: <a href="https://www.milenio.com/espectaculos/television/la-historia-detras-de-netflix-origenes-y-fundacion">https://www.milenio.com/espectaculos/television/la-historia-detras-de-netflix-origenes-y-fundacion</a>. [Consultado: 15-oct-2024].
- [2] W. Guerra y M. R. Ichaso, "Cronología de Netflix: así se convirtió en el gigante del streaming", CNN en Español, 18-jul-2022. [En línea]. Disponible en: <a href="https://cnnespanol.cnn.com/2022/07/18/cronologia-netflix-asi-se-convirtio-gigante-streaming-orix/">https://cnnespanol.cnn.com/2022/07/18/cronologia-netflix-asi-se-convirtio-gigante-streaming-orix/</a>. [Consultado: 15-oct-2024].
  - [3] Abhishek. "NETFLIX Stock Data". Kaggle: Your Machine Learning and Data Science Community. Accedido el 16 de octubre de 2024. [En línea]. Disponible:

https://www.kaggle.com/datasets/abhiram8/netflix-stock-data/code

[4] A. Kumar. "Netflix Reviews [DAILY UPDATED]". Kaggle: Your Machine Learning and Data Science Community. Accedido el 16 de octubre de 2024. [En línea]. Disponible:

https://www.kaggle.com/datasets/ashishkumarak/netflix-reviews-playstore-daily-updated/data

[5] A. Kumar. "Netflix Reviews [DAILY UPDATED]". Kaggle: Your Machine Learning and Data Science Community. Accedido el 16 de octubre de 2024. [En línea]. Disponible:

https://www.kaggle.com/datasets/ashishkumarak/netflix-reviews-playstore-daily-updated/data